Agentes de ventas con inteligencia artificial para comercio electrónico: revisión estructurada de la evidencia y propuesta de arquitectura multiagente a partir del análisis de dos sistemas existentes

Cristian Marín · Juan Manuel Goenaga

Filiación institucional: [pendiente de completar por los autores]

Manuscrito sin revisión por pares · Versión del 27 de octubre de 2026

Resumen

Los asistentes conversacionales basados en modelos de lenguaje de gran tamaño (LLM) se están incorporando al comercio electrónico como agentes de ventas, pero la evidencia sobre su arquitectura, eficacia y riesgos está dispersa entre literatura científica, documentación de ingeniería empresarial y comunicados comerciales. Este manuscrito presenta una revisión estructurada, de alcance limitado y reproducible en su estrategia de búsqueda, basada en 43 referencias verificadas, y la contrasta con el análisis estático de dos repositorios de código: un coach conversacional de IA con un superagente y agentes especializados (GoToGym Coach) y una tienda en línea (GoToGym Prime). La evidencia revisada indica que (a) las implementaciones empresariales documentadas combinan modelos con herramientas y recuperación de contexto, y describen estrategias multimodelo u orquestación multiagente; (b) la evidencia causal independiente es escasa y heterogénea —los experimentos de campo hallados reportan efectos sobre las ventas desde ningún efecto detectable hasta 16,3 % en un caso y de 3,00 % en otro—, mientras que las cifras de los proveedores carecen de metodología publicada; y (c) los riesgos principales (información incorrecta con consecuencias legales, inyección de instrucciones, agencia excesiva, privacidad y transparencia) cuentan con controles documentados. A partir de esa evidencia se propone una arquitectura en la que un superagente orquesta agentes especializados que solo leen y proponen, la tienda conserva la autoridad sobre precios, existencias y políticas, y cada respuesta se valida antes de publicarse. El análisis de los repositorios identifica además dos posibles brechas de cumplimiento en la tienda: un plazo de reembolso que no coincide con la normativa colombiana de comercio electrónico vigente y la ausencia de un canal de atención con número de radicado. La arquitectura no ha sido implementada ni evaluada: se presenta un protocolo de evaluación y no resultados experimentales.

Palabras clave: agentes conversacionales; comercio electrónico; modelos de lenguaje de gran tamaño; sistemas multiagente; alucinaciones; inyección de instrucciones; arquitectura de software.

1. Introducción

El comercio electrónico ha incorporado asistentes conversacionales que ya no se limitan a responder preguntas frecuentes: buscan, comparan y recomiendan productos, consultan el historial del cliente y, en algunos casos, ejecutan acciones. Amazon informa que su asistente Rufus fue usado por más de 250 millones de clientes en 2025, según la propia empresa (Park et al., 2025); Walmart presenta a Sparky como un asistente generativo integrado en su aplicación y describe un marco de "cuatro superagentes" orientado a clientes, asociados, socios y desarrolladores (Gosby, 2025; Walmart Inc., 2026b); Klarna comunicó resultados de su asistente de atención al cliente en su primer mes (Klarna, 2024) y en 2025 su director ejecutivo declaró que volvía a contratar personas para que "siempre haya un humano si se quiere" (Shibu, 2025; traducción propia). Estas fuentes son valiosas como descripción de práctica, pero son comunicaciones de las propias empresas y no equivalen a evidencia científica.

Al mismo tiempo, los fallos de estos sistemas tienen consecuencias comerciales y jurídicas. En *Moffatt v. Air Canada* (2024 BCCRT 149) un tribunal de Columbia Británica responsabilizó a una aerolínea por información incorrecta emitida por su *chatbot* y rechazó el argumento de que este fuese una entidad separada (McCarthy Tétrault, 2024). En diciembre de 2023, un asistente de un concesionario de automóviles fue inducido mediante instrucciones a "aceptar" la venta de un vehículo por un dólar, sin que la fuente reporte una transacción completada (AI Incident Database, 2023). En Colombia, la Ley 2439 de 2024 reforzó las obligaciones de información y de atención al consumidor en el comercio electrónico (Congreso de la República de Colombia, 2024), lo que convierte el rigor de las respuestas de un agente de ventas en una exigencia de cumplimiento y no solo de calidad de servicio.

Los autores disponen de dos sistemas relacionados: GoToGym Coach, un servicio de IA conversacional con un superagente que orquesta agentes especializados, y GoToGym Prime, una tienda en línea de ropa deportiva. La pregunta práctica es cómo incorporar un agente de ventas a la tienda aprovechando el Coach, sin comprometer la veracidad comercial ni la seguridad, y qué evidencia respalda las decisiones de diseño.

Contribuciones. Este trabajo aporta: (1) una revisión estructurada con estrategia de búsqueda explícita y clasificación de la calidad de la evidencia; (2) un análisis fundamentado en el código de ambos repositorios; (3) una propuesta de arquitectura y un plan general de implementación trazables a la evidencia; y (4) un protocolo de evaluación. **No** aporta resultados experimentales sobre el agente propuesto, porque este no ha sido implementado.

2. Preguntas de investigación y objetivos

La revisión y el análisis se guiaron por las siguientes preguntas:

- **PI1.** ¿Qué arquitecturas y capacidades se documentan en agentes conversacionales de ventas basados en LLM en comercio electrónico?
- **PI2.** ¿Qué evidencia existe sobre su efecto comercial y qué calidad tiene?
- **PI3.** ¿Cuáles son los riesgos principales y los controles que la literatura y la práctica documentan?
- **PI4.** ¿Qué capacidades de GoToGym Coach y GoToGym Prime son reutilizables, qué brechas existen y qué arquitectura, plan de implementación y pruebas se derivan?

Objetivo general. Fundamentar, con evidencia verificable y con el código existente, el diseño de un agente de ventas con IA para una tienda en línea. **Objetivos específicos:** (a) sintetizar la evidencia sobre arquitectura, efectividad y riesgos; (b) caracterizar los dos repositorios en lo relevante para el agente; (c) proponer una arquitectura y un plan general de implementación que conecten ambas cosas; (d) definir un protocolo de evaluación previo a cualquier despliegue.

3. Marco teórico

3.1 Sistemas conversacionales de recomendación y venta

Los sistemas de recomendación conversacionales buscan obtener preferencias y recomendar mediante diálogo en lugar de listas estáticas; Jannach et al. (2021) ofrecen una revisión del área. La incorporación de LLM amplía la comprensión del lenguaje y la generación, pero introduce los riesgos de fiabilidad que se discuten en las secciones 6.3 y 7. Existen conjuntos de evaluación específicos del dominio: WebShop simula un sitio de compras con 1,18 millones de productos reales y 12.087 instrucciones, y en él el mejor modelo alcanzó 29 % de éxito frente a 59 % de expertos humanos (Yao et al., 2022a); Shopping MMLU reúne 57 tareas de cuatro habilidades de compra y evaluó más de 20 LLM (Jin et al., 2024).

3.2 Agentes basados en LLM: razonamiento, herramientas y recuperación

Un agente basado en LLM combina generación de lenguaje con acciones sobre herramientas externas. ReAct intercala razonamiento y acción (Yao et al., 2022b); Toolformer estudia cómo los modelos aprenden a invocar herramientas (Schick et al., 2023); la generación aumentada por recuperación (RAG) incorpora conocimiento externo en la respuesta (Lewis et al., 2020). En esta revisión, la descripción de diseño de sistemas reales proviene sobre todo de documentación empresarial (sección 5), no de estudios revisados por pares.

Schluntz y Zhang (2024) distinguen *flujos de trabajo* (workflows), en los que el código predefine el camino que siguen LLM y herramientas, de *agentes*, en los que el modelo dirige dinámicamente su proceso y su uso de herramientas, y recomiendan "encontrar la solución más simple posible" y aumentar la complejidad solo cuando sea necesario. Esa distinción es central para el diseño propuesto.

3.3 Sistemas multiagente y "superagentes"

Los marcos multiagente permiten que varios agentes conversen para resolver tareas (Wu et al., 2023), pero sus ganancias en pruebas habituales suelen ser modestas y presentan modos de fallo propios, que Cemri et al. (2025) catalogan a partir de más de 1.600 trazas anotadas. El término "superagente" no tiene una definición única en la literatura revisada: Walmart lo usa para un marco de cuatro agentes por audiencia (Walmart Inc., 2026b). En este manuscrito, **superagente** designa al componente que recibe el turno, decide qué **agentes especializados** consultar, integra su evidencia y es el único que emite la respuesta; los agentes especializados son roles con herramientas y alcance de datos acotados. Es un uso ingenieril, coherente con el módulo *superagent* del repositorio del Coach (sección 8).

3.4 Alucinación y fundamentación

La alucinación —contenido fluido pero no sustentado en la fuente o en la realidad— ha sido sistematizada en revisiones sobre generación de lenguaje natural (Ji et al., 2023) y sobre LLM (Huang et al., 2025). El perfil de IA generativa del NIST incluye la *confabulación* entre los riesgos propios de esta tecnología (National Institute of Standards and Technology, 2024). La mitigación habitual es la fundamentación en fuentes controladas y la validación posterior de la salida.

3.5 Seguridad de agentes con herramientas

La inyección de instrucciones permite que el texto procesado altere el comportamiento del modelo (Perez y Ribeiro, 2022). Greshake et al. (2023) mostraron que en aplicaciones integradas con LLM la *inyección indirecta*, ubicada en datos que el sistema recupera, puede manipular el uso de herramientas. OWASP la sitúa como el riesgo LLM01 y describe como LLM06 la *agencia excesiva* (exceso de funcionalidad, de permisos o de autonomía) (OWASP GenAI Security Project, 2025a, 2025b). AgentDojo ofrece un entorno de evaluación con 97 tareas y 629 casos de seguridad para agentes que ejecutan herramientas sobre datos no confiables (Debenedetti et al., 2024), y se han propuesto patrones de diseño y defensas “por diseño” (Beurer-Kellner et al., 2025; Debenedetti et al., 2025).

3.6 Persuasión, transparencia y patrones oscuros

Un agente de ventas es un sistema persuasivo; Noels et al. (2024) revisan la evidencia y las implicaciones éticas de la persuasión con LLM. En comercio electrónico, Mathur et al. (2019) analizaron cerca de 53 mil páginas de producto de unos 11 mil sitios y hallaron 1.818 instancias de patrones oscuros, lo que ilustra el riesgo de diseñar presión indebida. Sobre transparencia, Luo et al. (2019) encontraron en un experimento de campo con llamadas de venta salientes que revelar la identidad del *chatbot* antes de la conversación redujo las compras en más de 79,7 %, mientras que el artículo 50 del Reglamento (UE) 2024/1689 exige que las personas sean informadas de que interactúan con un sistema de IA salvo que sea evidente (Parlamento Europeo y Consejo de la Unión Europea, 2024). Esa tensión se discute en la sección 11.

4. Metodología de la revisión

4.1 Diseño

Se realizó una **revisión estructurada de alcance limitado** (*rapid structured review*), no una revisión sistemática conforme a PRISMA: hubo un único proceso de búsqueda y cribado, sin doble revisión independiente ni protocolo preinscrito. La elección responde al objetivo (fundamentar decisiones de diseño) y al carácter muy reciente y cambiante del tema, en el que parte sustancial de la evidencia es literatura gris. Las limitaciones se detallan en la sección 12.

4.2 Fuentes y estrategia de búsqueda

La búsqueda se ejecutó el **27 de octubre de 2026** con tres mecanismos: (i) un motor de búsqueda web de propósito general (índice restringido a Estados Unidos) mediante **26 consultas** en inglés y español, listadas en el Apéndice A; (ii) la API de Crossref y la API de arXiv para verificar metadatos, autores, año y DOI de cada referencia candidata; y (iii) la apertura directa de páginas oficiales (AWS, Walmart, Shopify, Klarna, OWASP, Anthropic, NeurIPS, INFORMS/RePEc, NBER y normas colombianas). No se consultaron bases

bibliográficas con suscripción (Scopus, Web of Science) ni se rastrearon sistemáticamente las referencias de los trabajos incluidos.

4.3 Criterios de selección

Inclusión: (I1) la fuente describe o evalúa agentes o asistentes conversacionales con LLM en comercio, ventas o atención al cliente de comercio, o riesgos y controles aplicables a agentes con herramientas; (I2) es verificable (DOI, identificador arXiv, documento oficial o norma); (I3) está publicada entre 2019 y 2026. **Exclusión:** (E1) sitios agregadores y reseñas automáticas de artículos cuando existía la fuente primaria; (E2) contenido sin autoría o fecha; (E3) cifras de efecto comercial sin fuente primaria localizable. Las afirmaciones comerciales de proveedores se conservaron **solo** como descripción de práctica y se etiquetaron como tales.

4.4 Clasificación de la evidencia y verificación

Cada fuente se clasificó en uno de los niveles de la Tabla 1, que distingue el resultado científico de la afirmación comercial. Todas las referencias se verificaron en Crossref, en la API de arXiv o abriendo la página citada. La verificación detectó un error: un DOI recordado para un estudio sobre *chatbots* y satisfacción en marcas de lujo correspondía a otro artículo; se corrigió el identificador mediante búsqueda por título en Crossref y, al no aportar la lectura de su resumen a la síntesis, el estudio no se incluyó. Algunos textos no pudieron abrirse (Tabla 2); en esos casos el contenido se tomó de fuentes secundarias, que se señalan expresamente en el texto y en las referencias.

Tabla 1

Niveles de evidencia utilizados en la revisión

Nivel	Descripción	Ejemplos incluidos
E1	Estudio empírico revisado por pares, incluidos experimentos de campo	Luo et al. (2019); Wang et al. (2025); Brynjolfsson et al. (2025)
E2	Preprint, *benchmark* o artículo técnico con metodología descrita, sin revisión por pares confirmada en esta revisión	Yao et al. (2024); Fang et al. (2025); Debenedetti et al. (2024); Rajasekar et al. (2025)
E3	Documentación oficial o de ingeniería de una organización; resultados autorreportados	Park et al. (2025); McNamara (2025); Klarna (2024); OWASP (2025a)
E4	Prensa o comentario secundario	Shibu (2025); McCarthy Tétrault (2024); Cuatrecasas (s. f.)
N	Norma o jurisprudencia (primaria si se accedió al texto; secundaria en caso contrario)	Ley 2439 de 2024 (texto oficial leído); Reglamento (UE) 2024/1689 (réplica no oficial)

Tabla 2

Distribución de las 43 referencias y límites de acceso encontrados

Tipo de referencia	n	Observaciones de acceso
Artículos revisados por pares y actas de congreso	9	Metadatos verificados en Crossref o en la página de actas
Preprints en arXiv	14	Metadatos verificados con la API de arXiv; no se asumió publicación posterior
Documentación empresarial u oficial	10	Páginas abiertas; cifras tratadas como autorreportadas
Prensa y comentario jurídico	4	Usadas solo para hechos que carecían de fuente primaria accesible

Tipo de referencia	n	Observaciones de acceso
Normas y jurisprudencia	6	EUR-Lex devolvió respuesta vacía (HTTP 202); CanLII, HTTP 403; PDF de la SIC, HTTP 404; Secretaría del Senado, conexión rechazada; Función Pública, error de certificado

Nota. La Ley 2439 de 2024 se leyó en una copia en PDF del Diario Oficial n.º 52.975 reproducida por un sitio jurídico.

4.5 Análisis de los repositorios

Ambos repositorios se leyeron de forma **estática**, sin modificarlos. Se fijaron versiones: GoToGym Coach, confirmación *06ec012e*; GoToGym Prime, confirmación *a0e9d0e* (23 de octubre de 2026). Las métricas de tamaño y de pruebas provienen de comandos sobre los archivos versionados (*git ls-files*) y son aproximadas. Se ejecutó, en un entorno virtual aislado (Python 3.11.9, Django 5.2.18), el conjunto de pruebas de entrega de especialistas del Coach: 161 pruebas, sin fallos ni errores y una omitida. No se ejecutó ninguna prueba del repositorio de la tienda ni se contactó ningún servicio de producción.

4.6 Declaración sobre el uso de IA en este trabajo

La búsqueda bibliográfica, la lectura de los repositorios, la verificación de referencias y la redacción de borradores se realizaron con la asistencia de un modelo de IA (Claude, de Anthropic) ejecutado como agente de programación con acceso a herramientas de búsqueda web, lectura de archivos y ejecución de comandos. Los autores son responsables del contenido y deben revisar todas las afirmaciones, las referencias y las decisiones de alcance antes de cualquier envío editorial. Se declara aquí para que el lector pueda valorar la metodología con ese dato.

5. Implementaciones existentes: descripción de práctica y de resultados reportados

La Tabla 3 resume lo que las fuentes revisadas documentan. Se distingue lo descrito (arquitectura, capacidades) de lo *autorreportado* (resultados), y se omite lo que las fuentes no afirman.

Tabla 3

Implementaciones empresariales y técnicas documentadas

Sistema (fuente)	Qué documenta la fuente	Resultados reportados	Nivel
Amazon Rufus (Park et al., 2025)	Estrategia que “combina múltiples modelos” (modelo propio especializado en compras, Amazon Nova y Claude Sonnet); contexto conocido, como historial de pedidos, incluido en la solicitud o recuperado mediante una llamada a herramienta; recuperación y citación de fuentes web con *Nova Web Grounding*; caché de *prompts* y llamadas a herramientas en paralelo para reducir la latencia.	Más de 250 millones de clientes lo usaron “este año”; quienes lo usan en su recorrido serían “60 % más probables” de comprar. La fuente no describe metodología, grupo de comparación ni control de sesgo de selección.	E3
Walmart Sparky (Gosby, 2025; Walmart Inc., 2026a, 2026b)	Asistente generativo en la aplicación: busca, compara, sintetiza reseñas y recomienda; marco de cuatro superagentes por audiencia; menciona orquestación multiagente y manejo de contingencias. En octubre de 2026 anuncia reglas para agentes que compran en nombre de clientes: aprobación del cliente por defecto, límites de gasto, perfil propio del agente, sin datos de tarjeta.	Sin métricas en las fuentes consultadas.	E3

Sistema (fuente)	Qué documenta la fuente	Resultados reportados	Nivel
Shopify Sidekick (McNamara, 2025)	Asistente para comerciantes con bucle agéntico; guía cualitativa sobre número de herramientas (0–20 claras; 50 o más difíciles de razonar); instrucciones "justo a tiempo" junto a los datos de la herramienta; evaluación con juez-LLM calibrado contra etiquetas humanas, conjuntos de verdad construidos con conversaciones reales y simulador de usuario; detección de *reward hacking*.	Acuerdo del juez con humanos de κ = 0,02 a 0,61 (referencia humana 0,69); precisión de validación sintáctica de ~93 % a ~99 %. Sin tamaños de muestra.	E3
Klarna (atención al cliente) (Klarna, 2024; Shibu, 2025)	Asistente con tecnología de OpenAI para atención al cliente (no es un asistente de ventas).	Comunicado de 2024: 2,3 millones de conversaciones en el primer mes, dos tercios de los chats, equivalente a 700 agentes, resolución en menos de 2 minutos frente a 11, 25 % menos de consultas repetidas y satisfacción "a la par" (sin cifra). En 2025 el CEO declaró a Bloomberg que volvía a contratar personas.	E3 / E4
Flippi (Rajasekar et al., 2025)	Asistente de comercio electrónico de extremo a extremo con reformulación de consultas, detección de intención, RAG, reconocimiento de entidades, reducción de contexto, identificación de ofertas y comparación de productos.	El resumen presenta un marco de evaluación (desempeño, satisfacción, conversión); no se extraen cifras en esta revisión.	E2

Nota. Las cifras son las que cada fuente declara; ninguna fue replicada o auditada de forma independiente por los autores de este manuscrito.

6. Resultados de la revisión

6.1 Arquitecturas y capacidades recurrentes (PI1)

Las fuentes de práctica (Tabla 3) convergen en seis patrones, que se formulan aquí como **síntesis de los autores** a partir de lo descrito, no como hallazgo cuantificado:

- **P1. Modelo más herramientas y contexto del cliente.** Rufus recupera contexto con herramientas (Park et al., 2025); Flippi compone reformulación, intención y RAG (Rajasekar et al., 2025); Sparky combina orquestación multiagente y manejo de contingencias (Walmart Inc., 2026b).
- **P2. Multimodelo y enrutamiento.** Rufus declara una estrategia que combina varios modelos y selecciona el adecuado por tipo de consulta (Park et al., 2025).
- **P3. Superficie de herramientas acotada.** Sidekick distingue rangos de herramientas según la dificultad de razonar sobre ellas (McNamara, 2025), en coherencia con la mitigación de OWASP de limitar extensiones y permisos (OWASP GenAI Security Project, 2025b).
- **P4. Evaluación con jueces-LLM calibrados y con conversaciones reales.** Sidekick lo describe con métricas de acuerdo (McNamara, 2025); Rufus menciona juez-LLM sin publicar resultados (Park et al., 2025).
- **P5. Presencia humana disponible.** Klarna rectifica hacia la contratación de personas (Shibu, 2025); en Colombia, la Ley 2439 de 2024 exige canales de atención en el mismo medio con trazabilidad (Congreso de la República de Colombia, 2024).
- **P6. Delegación controlada.** Para agentes que compran en nombre del cliente, Walmart describe consentimiento por defecto, límites de gasto, perfil separado y acceso mínimo a información (Walmart Inc., 2026a).

6.2 Evidencia sobre efectividad (PI2)

La Tabla 4 reúne los estudios con diseño empírico hallados. Ninguno evalúa un asistente de compras basado en LLM en una tienda en línea convencional: Wang et al. (2025) estudian un asistente de chat en una plataforma de venta por transmisión en vivo; Luo et al. (2019), *chatbots* de venta por llamada; Fang et al. (2025) y Brynjolfsson et al. (2025), otros flujos de IA generativa. Su transferencia a una tienda pequeña de ropa deportiva es una hipótesis, no un hecho.

Tabla 4

Estudios con diseño empírico sobre efectos de chatbots e IA generativa en ventas y atención

Estudio	Diseño y contexto	Resultados principales	Cautelas
Fang et al. (2025)	Experimentos de campo aleatorizados con millones de usuarios en una plataforma de comercio transfronterizo; siete flujos (atención, emparejamiento consumidor-producto, publicidad, servicios a vendedores), 2023–2024.	Efectos sobre ventas desde ningún efecto detectable hasta 16,3 %; mejoras por mayor conversión, no por mayor valor del carrito; devoluciones y calificaciones no empeoran; mayor beneficio en consumidores con menos experiencia.	Preprint; no es solo un asistente conversacional; plataforma de gran escala.
Wang et al. (2025)	Experimento de campo aleatorizado en una plataforma de venta por transmisión en vivo; asistente de IA en chat.	Aumento de 3,00 % en ventas y reducción de 12,55 % en devoluciones; en ocasiones interrumpe la experiencia.	Contexto de *livestream*, distinto de una tienda tradicional.
Luo et al. (2019)	Experimento de campo con más de 6.200 clientes en llamadas de venta salientes, *chatbots* frente a trabajadores.	Chatbots no revelados tan eficaces como trabajadores competentes y cuatro veces más que los inexpertos; revelar antes de la conversación reduce las compras en más de 79,7 %; revelar más tarde atenúa el efecto.	Canal de voz saliente (no chat web); estudio anterior a los LLM actuales.
Brynjolfsson et al. (2025)	Despliegue escalonado de un asistente generativo a 5.179 agentes de atención al cliente.	Productividad (problemas resueltos por hora) aproximadamente 14 % mayor; 34 % en personal novato; efecto mínimo en personal experto.	Atención al cliente, no ventas.

En contraste, las cifras de proveedores (p. ej., “60 % más probables” de comprar con Rufus, o el equivalente a 700 agentes de Klarna) no vienen acompañadas de diseño experimental publicado en las fuentes consultadas (Klarna, 2024; Park et al., 2025). Esta revisión no extrae de ellas conclusiones causales.

6.3 Fiabilidad de los agentes en tareas de comercio (PI2)

Los *benchmarks* indican que la fiabilidad dista de ser plena. En τ-bench, que simula conversaciones entre un usuario y un agente con herramientas de dominio y reglas de política, incluso agentes de última generación resolvían menos de la mitad de las tareas y eran inconsistentes (pass^8 inferior a 25 % en el dominio retail) (Yao et al., 2024). La métrica pass^k mide la fiabilidad en varios intentos y es pertinente para un agente que atenderá muchas conversaciones. Estos resultados corresponden a modelos de mediados de 2024; no deben extrapolarse a los modelos actuales sin evaluarlos.

7. Riesgos y controles documentados (PI3)

La Tabla 5 relaciona cada riesgo con la evidencia que lo sustenta y con el control que se incorpora a la arquitectura propuesta. Los controles de la columna final son **propuestas de diseño** de los autores, no resultados verificados.

Tabla 5

Riesgos, evidencia y controles propuestos

Riesgo	Evidencia	Control propuesto
R1. Información incorrecta (alucinación) con consecuencias legales	Ji et al. (2023); Huang et al. (2025); NIST (2024); *Moffatt v. Air Canada* (McCarthy Tétrault, 2024); Ley 2439 de 2024, art. 4 (nueva redacción del art. 50 de la Ley 1480).	Precio, existencias, cupones y políticas solo desde la tienda; validación de cifras citadas contra la evidencia del turno; lista de afirmaciones prohibidas; fallo explícito en lugar de respuesta de reemplazo.
R2. Presión comercial indebida y recomendaciones inadecuadas	Mathur et al. (2019); Noels et al. (2024); Fang et al. (2025) (devoluciones como indicador).	Prohibición de urgencia o escasez falsa; la guía de tallas se presenta como referencia general; devoluciones y quejas como métricas de resguardo.
R3. Inyección de instrucciones directa e indirecta	Perez y Ribeiro (2022); Greshake et al. (2023); OWASP (2025a); Debenedetti et al. (2024); incidente del concesionario (AI Incident Database, 2023).	Descripciones, reseñas y mensajes tratados como datos; salida estructurada validada por código determinista; lista blanca de acciones; sin secretos en el contexto; pruebas adversarias.
R4. Agencia excesiva	OWASP (2025b); controles de delegación de Walmart Inc. (2026a).	El agente solo propone; el navegador ejecuta con los permisos del propio visitante; autorización en el sistema aguas abajo; límites de uso.
R5. Privacidad y datos personales	Ley Estatutaria 1581 de 2012 (Congreso de la República de Colombia, 2012); Circular Externa 002 de 2024 de la Superintendencia de Industria y Comercio [SIC] (SIC, 2024; consultada vía Cuatrecasas, s. f.).	Minimización (sin correo, teléfono, documento ni dirección en el paquete); sujeto seudónimo; aviso y política actualizados; evaluación de impacto cuando proceda.
R6. Transparencia frente al usuario	Reglamento (UE) 2024/1689, art. 50.1; Luo et al. (2019).	Aviso de que se trata de un asistente de IA en la primera interacción; medición del efecto del aviso en el experimento (no su omisión).
R7. Variabilidad y fallos multiagente	Yao et al. (2024); Cemri et al. (2025).	Pocos agentes con herramientas acotadas; orquestación con reglas explícitas; evaluación repetida (pass^k).
R8. Dependencia del proveedor, cuota y latencia	Estrategia multimodelo (Park et al., 2025); incidente interno de rechazos HTTP 429 documentado en el Coach (sección 8.2).	Presupuesto de tamaño del contexto; interruptor de apagado; error explícito con reintento; acoplamiento por contrato versionado.
R9. Cumplimiento comercial local	Ley 2439 de 2024, arts. 3 y 4 (información cierta y actualizada, canales con radicado, devolución del dinero en comercio electrónico).	Traspaso humano que genere un radicado; políticas desde una fuente única; revisión jurídica de textos y plazos.

8. Análisis de los repositorios (PI4)

8.1 Alcance

Se analizaron GoToGym Coach (confirmación *06ec012e*) y GoToGym Prime (confirmación *a0e9d0e*) conforme a la sección 4.5. Las afirmaciones de esta sección se apoyan en archivos concretos de cada repositorio. Lo que no pudo verificarse se señala como **hipótesis**. Los hallazgos de seguridad operativa del Coach se describen solo de forma general, por su carácter sensible.

8.2 GoToGym Coach

El Coach es un monolito Django en Python, con aproximadamente 157 mil líneas de código de producción (incluidos *scripts*), 58 mil líneas de pruebas, 2.697 funciones de prueba (conteo estático) y 297 archivos de prueba en su paquete principal. Su documento de reglas de integración (*AGENTS.md*) y su guía de resultados interpretados establecen invariantes verificables que condicionan cualquier extensión: reutilizar el pipeline canónico existente sin crear otro narrador, router por palabras clave ni escritor de estado; no confundir propuesta con acción ejecutada; ligar toda referencia al sujeto, conversación y turno actuales; y no publicar como interpretada una respuesta cuando falla el observador, la narración o la validación.

Tabla 6

Capacidades de GoToGym Coach relevantes para un agente de ventas

Capacidad	Evidencia en el código	Relevancia
Aislamiento por rol de IA	*superagent/ai_role_isolation.py*: roles PERSONAL, BUSINESS y ADMIN con política de datos, memoria y herramientas; el rol lo fija el llamador de confianza y falla cerrado.	Base para un rol nuevo sin acceso a datos personales ni de salud.
Pipeline único de respuesta	*superagent/canonical_conversation_pipeline.py* (≈2.100 líneas): prepara evidencia, observa, narra y valida; su constructor acepta *evidence_providers* y *tool_registry* como parámetros.	Permite inyectar proveedores y herramientas propios sin editar el pipeline.
Proveedores de evidencia con rol declarado	*superagent/canonical_evidence.py*: cada proveedor declara *supported_roles*; *assert_provider_role* rechaza el uso fuera de rol y exige que el actor del usuario coincida con el del contexto.	Patrón a replicar; la exigencia de actor condiciona la identidad de servicio (hipótesis H-ID).
Registro de herramientas con permisos	*superagent/tool_registry.py* y *permissions.py*: cada herramienta declara riesgo, alcance de memoria, confirmación requerida y si escribe estado; *can_execute_tool* deniega por modo, alcance o falta de confirmación.	Mapea el principio de mínima agencia (OWASP, 2025b).
Rol no personal ya construido	*superagent/business_tools.py*, *business_evidence.py* y rama del *endpoint* de chat para el rol BUSINESS.	Plantilla probada para un rol nuevo.
Cliente de modelo y diagnóstico	*llm/azure_client.py*: manejo de rechazo por límite de tasa y diagnósticos numéricos sin texto del proveedor.	Soporta fallo explícito con reintento.
Pruebas y compuertas	Compuerta de entrega de especialistas: 161 pruebas ejecutadas en esta revisión, sin fallos (1 omitida).	Cultura de pruebas de contrato; los cambios nuevos deben integrarse a ella.

Evidencia operativa propia. La documentación interna del Coach registra que, el 25 de octubre de 2026, la telemetría de producción midió solicitudes de 1.951.397 y 1.978.029 bytes al explicar un resultado, con respuesta HTTP 429, límite de 10.000 tokens y tokens restantes en cero; la corrección consistió en acotar el contexto enviado sin borrar el historial. Es evidencia interna, no independiente, pero respalda el requisito de presupuesto de contexto del diseño propuesto (riesgo R8).

Limitaciones relevantes para este proyecto. (i) La capa HTTP está concentrada en un módulo de unas 40 mil líneas, por lo que los endpoints nuevos deben vivir en módulos nuevos. (ii) La configuración global de permisos de la API es permisiva por defecto, de modo que todo endpoint nuevo debe declarar autenticación y permiso de forma explícita. (iii) El chat actual exige un usuario autenticado del Coach, mientras que los visitantes de la tienda son mayormente anónimos y su identidad es otra. (iv) El pipeline asume un objeto de usuario con *id* coincidente con el actor del contexto; que un sujeto de servicio lo satisfaga **no está probado** (hipótesis H-ID). (v) Existen unas dieciocho líneas que mencionan los roles BUSINESS o ADMIN fuera de sus propios módulos; podrían tratar un rol nuevo como "no personal" de forma no deseada (hipótesis H-ROL). (vi) Una revisión preliminar de higiene de seguridad del repositorio identificó elementos que deben corregirse antes de exponer servicios nuevos; no se detallan aquí.

8.3 GoToGym Prime

Prime es un monolito Django 5.2.18 con plantillas renderizadas en el servidor, CSS compilado y JavaScript sin *bundler*; en producción usa PostgreSQL y Azure App Service (según su documentación de despliegue del 14 de octubre de 2026, que no se contrastó con Azure). Su configuración de integración continua ejecuta *ruff*, *import-linter* (capas entre aplicaciones sin ciclos), *mypy*, pruebas con cobertura y una compuerta de gobernanza de diseño; el repositorio contiene 83 archivos de prueba.

Tabla 7

Capacidades de GoToGym Prime relevantes para un agente de ventas

Capacidad	Evidencia en el código	Implicación
Unidad vendible y precio	*products/models.py*: la unidad es *ProductVariant* (SKU, talla, color); *effective_price* devuelve el precio con descuento solo si es menor que el normal.	Fuente de verdad del precio; el agente no debe calcularlo.
Existencias	*inventory/services.py*: *get_available_quantity* lee de la base de datos; descuento con bloqueo y actualización condicional.	Disponibilidad real por turno; evita recomendar lo agotado.
Carrito	*carrito/services.py*: sesión *{id de variante: cantidad}* versionada; precio y disponibilidad recalculados en servidor; endpoints de agregar, actualizar y quitar con CSRF y límite de uso en agregar.	Las acciones propuestas pueden ejecutarse con endpoints existentes.
Checkout y cupones	*orders/services.py*: pedido en una transacción con precios congelados; cupones con vigencia, usos máximos, compra mínima, exclusión de autorreferencia de afiliados y segmentos de cliente; checkout exige sesión; pausa de compras.	El agente no aplica cupones ni crea pedidos.
Pagos y envío	Proveedor de pago simulado por defecto; Mercado Pago construido y, según su documentación, sin probar con credenciales reales; cotización de envío simulada (tarifa plana por ciudad).	El agente no debe prometer medios de pago ni plazos exactos.
Gobierno de afirmaciones	*gotogym/afirmaciones.py*: lista de afirmaciones aprobadas (vacía) y de afirmaciones prohibidas, con una prueba que impide su uso en plantillas.	Fuente reutilizable para el control R1.
Analítica y consentimiento	*analitica/*: eventos de primera parte, solo con consentimiento y respetando DNT y GPC; taxonomía cerrada que descarta en silencio eventos no declarados.	Los eventos del vendedor deben declararse.
Canal de atención	*static_pages/contacto.html*: correo y teléfono; no se halló modelo de solicitudes ni radicado; el formulario de suscripción del pie envía a una vista que no procesa envíos.	Falta un canal con registro para el traspaso humano.
Idiomas	Español e inglés con prueba que falla ante texto en español en */en/*.	El panel debe estar traducido.

Capacidad	Evidencia en el código	Implicación
Barra superior	*templates/base.html*: acciones de la barra (búsqueda, idioma, carrito, usuario) y prueba de contrato del encabezado.	Punto de inserción del botón del agente.

Limitaciones. No se ejecutaron las pruebas de Prime. No existe una API REST (el framework REST no figura entre sus dependencias): los datos se exponen mediante plantillas, por lo que una consulta bajo demanda desde el Coach requeriría un *endpoint* interno nuevo. No se halló una política de seguridad de contenido (CSP) definida. Según su documentación, tras una migración de catálogo hay productos con inventario cero.

8.4 Capacidades reutilizables y brechas

Tabla 8

Capacidades requeridas, estado en cada repositorio y acción

Capacidad requerida	Coach	Prime	Acción
Orquestación y respuesta única	Sí	—	Reutilizar sin modificar
Aislamiento por rol y alcance de datos	Sí (3 roles)	—	Añadir rol de comercio (registro mínimo)
Evidencia con fuente y versión	Sí	Datos en BD y servicios	Proveedor nuevo alimentado por el paquete de Prime
Herramientas con permisos	Sí	—	Registro propio inyectado al pipeline
Validación de afirmaciones y cifras	Parcial	Lista de prohibidas	Validador nuevo que reutilice la lista
Fuente de verdad de precio y existencias	—	Sí	Paquete por turno; el agente no recalcula
Acciones sobre el carrito	—	Sí	Ejecución en el navegador desde lista blanca
Identidad del visitante	Usuarios del Coach	Sesión y anónimos	Identidad de servicio y sujeto seudónimo (H-ID)
Límite de uso y de costo	Telemetría de proveedor	*rate_limit* por caché	Límites en el puente; presupuesto de contexto
Canal humano con trazabilidad	Notificaciones	Solo correo y teléfono; sin radicado (verificado en código)	Construir canal con radicado (prerrequisito; Ley 2439)
Pruebas y CI	Compuerta de entrega	CI con linters y capas	Pruebas nuevas en ambos; contrato versionado

8.5 Hallazgos de conformidad normativa en la tienda

La política de devoluciones de Prime indica que el reembolso se hace “a más tardar dentro de los 30 días calendario siguientes a la fecha en que ejerciste el derecho” (*gotogym/politicas_contenido.py*). El artículo 3 de la Ley 2439 de 2024, según el texto del Diario Oficial n.º 52.975 leído en esta revisión, modifica el artículo 47 de la Ley 1480 de 2011 (Congreso de la República de Colombia, 2011) y dispone que, en comercio electrónico, la devolución del dinero “no podrá exceder de quince (15) días calendario desde el momento en que ejerció el derecho”, siempre que el consumidor suministre los datos correctos y devuelva el producto (Congreso de la República de Colombia, 2024). Además, el artículo 4 reforma el artículo 50 de esa ley: exige información “cierta, fidedigna, suficiente, clara y actualizada” sobre el producto, plazo de validez de la oferta y disponibilidad, y canales de atención en el mismo medio que garanticen trazabilidad con

número de registro; para los literales b), g) y h) la vigencia es de cuatro meses posteriores a la publicación. **Este es un posible desajuste detectado por los autores, no un dictamen jurídico**: debe contrastarse con asesoría legal y con el texto consolidado vigente. Importa para el agente porque, si cita la política vigente en el sitio, podría reproducir un plazo desactualizado; por eso la arquitectura propuesta exige una fuente única de políticas.

Segundo hallazgo: canal de atención. La página de contacto de Prime ofrece únicamente un correo electrónico y un teléfono, y no se halló en el código ningún modelo de solicitudes ni número de radicado (búsqueda de los términos *radicado*, *pqr* y modelos de contacto). Además, el formulario "Mantenerme informado" del pie envía a la vista de contacto, que solo renderiza la página y no guarda el envío. El literal g) del artículo 50 reformado exige canales de atención en el mismo medio, con constancia mediante número de registro, fecha y hora y un mecanismo de seguimiento (Congreso de la República de Colombia, 2024). Esta exigencia existe con independencia del agente, pero lo condiciona: el traspaso humano necesita un destino que genere ese registro. No se descarta un sistema externo no versionado en el repositorio.

9. Arquitectura propuesta

9.1 Principios de diseño derivados de la evidencia

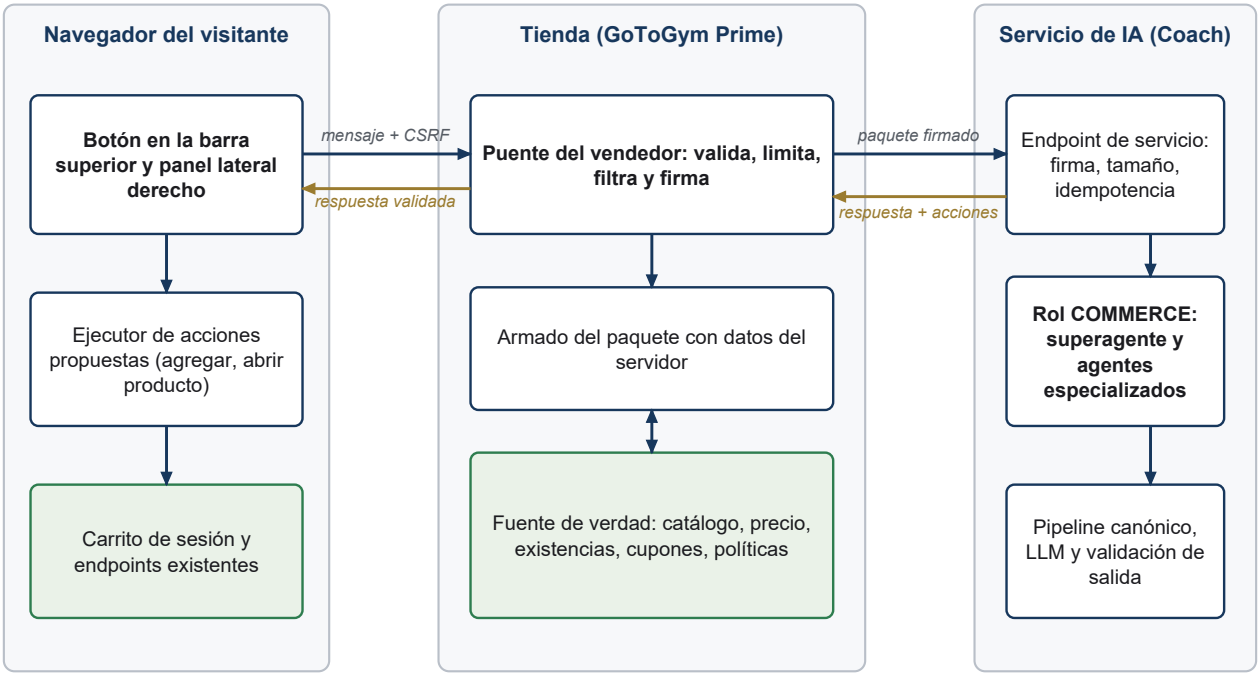
Los principios siguientes vinculan decisiones de diseño con las fuentes revisadas; son **propuestas** de los autores:

- **A. La tienda es la fuente de verdad** de precio, existencias, cupones y políticas (R1; Congreso de la República de Colombia, 2024; Civil Resolution Tribunal of British Columbia, 2024).
- **B. El agente propone; el navegador ejecuta** con los permisos del visitante (R4; OWASP GenAI Security Project, 2025b; Walmart Inc., 2026a).
- **C. Una sola voz.** Los agentes especializados aportan evidencia y el pipeline canónico redacta, siguiendo las reglas internas del Coach; se evita una cadena de agentes que conversan entre sí (Cemri et al., 2025).
- **D. Alcance mínimo de datos.** El rol de comercio no accede a datos personales ni de salud del Coach (R5).
- **E. Empezar simple.** Un flujo con roles y herramientas acotadas antes que autonomía abierta (Schluntz y Zhang, 2024; McNamara, 2025).
- **F. Fallo explícito y presencia humana** (R8, R9; Shibu, 2025).
- **G. Evaluar con repetición** y con pruebas adversarias antes de exponer al público (R3, R7; Yao et al., 2024; Debenedetti et al., 2024).

9.2 Visión general

Figura 1

Arquitectura propuesta y fronteras de confianza



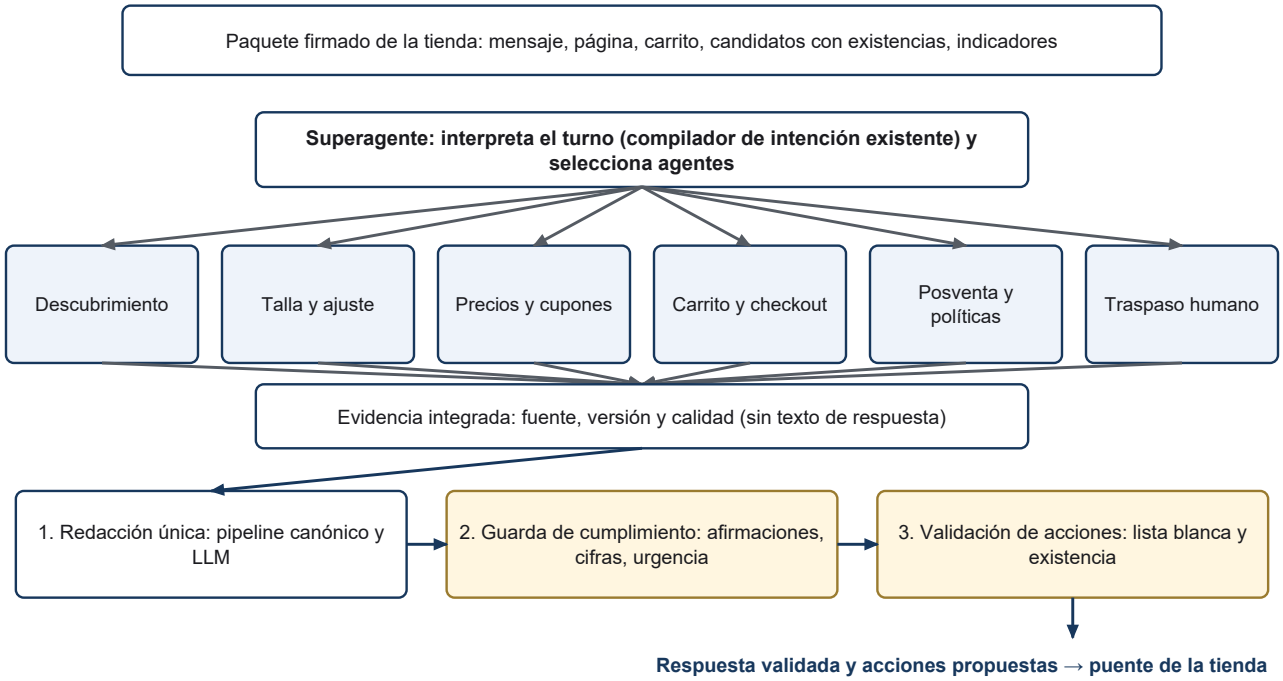
Nota. Flechas azules: solicitud; flechas doradas: respuesta. El navegador nunca contacta al Coach. Las acciones propuestas se ejecutan con los endpoints existentes del carrito. Elaboración propia.

9.3 Superagente y agentes especializados

El **superagente** interpreta el turno con el compilador de intención ya existente en el Coach (no se crea un enrutador por palabras clave), selecciona los agentes pertinentes y reúne su evidencia. Los agentes especializados no redactan: devuelven evidencia estructurada con fuente, versión y calidad; el pipeline canónico produce la única respuesta, que luego pasa por la guarda de cumplimiento y por la validación de acciones (Figura 2). La Tabla 9 resume los roles. El número de herramientas se mantiene bajo a propósito (McNamara, 2025).

Figura 2

Orquestación de un turno: superagente, agentes especializados y guardas de salida



Nota. Los agentes especializados aportan evidencia; una única narración sale del pipeline canónico. Si la guarda o la validación fallan, se devuelve un error con opción de reintento y no una respuesta de reemplazo. Elaboración propia.

Tabla 9

Agentes especializados propuestos

Agente	Responsabilidad	Evidencia que aporta	Regla dura
Descubrimiento y recomendación	Entender uso, presupuesto y estilo; ordenar opciones.	Candidatos con precio y existencias del turno.	Solo productos activos y con existencias.
Talla y ajuste	Orientar la talla y pedir medidas.	Guía de tallas y variantes disponibles.	La guía es referencia general, no medida verificada.
Precios, ofertas y cupones	Explicar precio efectivo, descuento y compra mínima; interpretar un código que el usuario aporta.	Precio efectivo y reglas del cupón.	No adivina ni lista códigos; no calcula.
Carrito y checkout	Leer el carrito, proponer acciones, explicar pasos y envío estimado.	Carrito del turno; estimación de envío.	Solo propone; respeta la pausa de compras; envío estimado.
Posventa y políticas	Estado del pedido propio; cambios, retracto, garantía y envíos.	Texto de la política con fuente y versión.	Cita la política vigente; si no existe, deriva.
Traspaso humano	Escalar ante queja, duda o riesgo.	Solicitud de contacto.	Solicita a la tienda crear la solicitud con radicado; nunca inventa números ni finge haber contactado.
Cumplimiento (guarda)	Revisar el borrador antes de publicar.	Lista de afirmaciones prohibidas; evidencia del turno.	Bloquea claims no aprobados, afirmaciones de salud y urgencia falsa.

9.4 Contrato entre la tienda y el Coach

El servidor de la tienda arma por turno un paquete acotado y firmado (HMAC con marca de tiempo) y recibe una respuesta con texto validado, acciones propuestas desde una lista blanca (agregar al carrito, abrir producto, ir al checkout, abrir contacto), tarjetas de producto, traspaso opcional y metadatos (agentes usados, referencias de evidencia, estado y tiempo de espera sugerido). El paquete no contiene correo, teléfono, documento, dirección ni códigos de afiliado; usa un sujeto seudónimo; expresa los precios como texto decimal; y está sujeto a un presupuesto de tamaño (propuesta: 24 KB y ocho candidatos, valores por confirmar). El Apéndice B ofrece un ejemplo del contrato.

9.5 Cambios por repositorio

Tabla 10

Cambios propuestos en cada repositorio

Repositorio	Código nuevo	Registros mínimos en archivos existentes	Sin modificar
Coach	Módulos de proveedor de evidencia, herramientas, superagente, agentes y guarda de cumplimiento; endpoint de servicio con autenticación de servicio y su propio archivo de rutas; autenticación por firma; pruebas; documentación.	(1) Valor nuevo del enum de roles y su política en *ai_role_isolation.py* (un enum no se amplía desde otro archivo). (2) Una línea *include* de rutas. Por verificar: si la regla de la matriz de pruebas de entrega aplica a un rol.	Pipeline, narrador, estado de trabajo, */api/chat/*, *tool_registry.py* por defecto, roles actuales, motores de salud, base de datos.
Prime	Aplicación nueva del puente; servicio de evidencia; canal de atención con radicado; parcial del panel, JavaScript y CSS propios; pruebas.	Botón en *base.html* (barra y menú móvil); declaración de la app en la configuración de capas; eventos en la taxonomía de analítica; textos de política de datos; traducciones; variables de entorno.	Checkout, pagos, inventario, catálogo, lista de afirmaciones (solo se reutiliza).

10. Plan general de implementación y protocolo de evaluación

10.1 Etapas

El plan se ordena por dependencias y no asume duraciones. Ninguna etapa se declara cumplida sin su criterio de salida, y la exposición a visitantes reales solo ocurre tras las etapas 4 y 5.

Tabla 11

Etapas, entregables y criterios de salida

Etapa	Contenido	Criterio de salida
0. Decisiones	Dónde vive el agente; identidad de servicio; visitantes anónimos; canal humano; textos legales; presupuesto de modelo.	Decisiones registradas y aprobadas por producto, jurídica y tecnología.
1. Prueba de concepto de identidad	Verificar que un sujeto de servicio satisface el pipeline y que un rol nuevo no cae en ramas de roles actuales (H-ID, H-ROL).	El pipeline responde para el rol nuevo sin alterar los roles existentes.
2. Tienda con Coach simulado	Botón, panel, puente, paquete, validación de respuesta, analítica, traducciones.	Pruebas de Prime y CI en verde; sin colores nuevos en plantillas; ES/EN completos.

Etapa	Contenido	Criterio de salida
2b. Canal de atención y políticas	Solicitud de atención con radicado, fecha y hora y seguimiento en la tienda; revisión jurídica del texto de reembolso.	Radicado operativo; texto de reembolso validado por asesoría.
3. Rol de comercio en el Coach	Proveedor, herramientas, agentes, guarda, endpoint de servicio, pruebas de aislamiento y de fallo.	Pruebas nuevas y compuertas del Coach en verde; fallo del modelo produce error explícito.
4. Integración en entorno de pruebas	Conexión real con modelo y datos de prueba; suites de evaluación (10.2).	Criterios a priori de veracidad y seguridad cumplidos; latencia y costo medidos.
5. Piloto controlado	Exposición limitada con interruptor de apagado y revisión humana de transcripciones.	Sin incidentes de veracidad ni de seguridad según criterios definidos; decisión de continuar.
6. Experimento comercial	Asignación aleatoria por visitante; medición de conversión y métricas de resguardo.	Análisis conforme al protocolo prerregistrado.

10.2 Protocolo de evaluación propuesto

Lo siguiente es un **protocolo**, no resultados. Los umbrales numéricos de aceptación deben fijarse antes de ejecutar las pruebas; este manuscrito no los inventa.

Tabla 12

Capas de evaluación

Capa	Qué verifica	Fundamento
Escenarios de compra con políticas	Conjunto de conversaciones de compra, talla, cupón y posventa construido con las reglas reales de la tienda; fiabilidad en varios intentos por escenario (pass^k) y comparación del estado final contra el estado esperado.	Yao et al. (2024)
Veracidad	Coincidencia de cada precio, existencia, plazo y cita de política del texto con la evidencia del turno; ninguna afirmación de la lista de prohibidas.	Ji et al. (2023); Congreso de la República de Colombia (2024)
Seguridad adversaria	Inyección directa (mensajes del usuario) e indirecta (descripciones, reseñas); intentos de obtener acciones fuera de la lista blanca, de revelar instrucciones o de forzar precios.	Greshake et al. (2023); Debenedetti et al. (2024); OWASP (2025a)
Aislamiento y privacidad	El rol de comercio no recibe datos personales ni de otros roles; el paquete no contiene datos personales.	OWASP (2025b); SIC (2024)
Calidad conversacional	Muestra revisada por personas con una rúbrica; si se usa un juez-LLM, calibración previa contra etiquetas humanas.	McNamara (2025)
Experimento en línea	Asignación aleatoria por visitante; resultado primario: conversión; métricas de resguardo: devoluciones, quejas, traspasos y errores.	Fang et al. (2025); Wang et al. (2025)

Hipótesis. H1 (veracidad): las respuestas del agente son consistentes con la evidencia del turno en una proporción superior al umbral fijado a priori. H2 (seguridad): ninguna prueba adversaria logra una acción fuera de la lista blanca. H3 (efecto comercial): la presencia del agente modifica la conversión respecto del grupo de control; **no se anticipa la dirección ni la magnitud**, dada la heterogeneidad observada en la literatura (Tabla 4). No se realizó cálculo de tamaño muestral.

11. Discusión

Evidencia y decisión. La literatura apoya la plausibilidad de beneficios comerciales de la IA generativa en comercio electrónico (Fang et al., 2025; Wang et al., 2025), pero su magnitud depende del contexto: va de ningún efecto detectable a 16,3 % en un estudio y a 3,00 % en otro. Ninguna fuente hallada evalúa un asistente de compras basado en LLM en una tienda pequeña de ropa deportiva. Por ello, el plan evita basar la decisión en cifras de proveedores y propone medir.

Agentes frente a flujos de trabajo. Schluntz y Zhang (2024) aconsejan la solución más simple, y Cemri et al. (2025) documentan fallos propios de los sistemas multiagente. La arquitectura propuesta no es un conjunto de agentes autónomos que conversan: es un flujo con roles especializados que aportan evidencia y una sola narración. Se trata de una interpretación de los autores, coherente con las reglas internas del Coach, y no de una validación de que esta separación supere a un único agente con herramientas; esa comparación queda como pregunta empírica abierta.

Transparencia y conversión. Luo et al. (2019) hallaron que revelar al *chatbot* antes de la conversación redujo mucho las compras, aunque en llamadas salientes de voz y con tecnología previa a los LLM actuales. El artículo 50.1 del Reglamento (UE) 2024/1689 exige informar al usuario salvo que sea evidente, y su aplicación y eventuales reformas deben verificarse (la búsqueda arrojó comentarios secundarios que mencionan directrices de la Comisión y una simplificación normativa en curso, no contrastados con fuente oficial). No se localizó en esta revisión una norma colombiana equivalente específica para *chatbots*, lo cual no prueba que no exista. La propuesta mantiene el aviso y plantea medir su efecto, en lugar de omitirlo por razones comerciales.

Responsabilidad. La decisión de *Moffatt v. Air Canada*, conocida aquí por un comentario jurídico, sugiere que la organización responde por lo que dice su *chatbot* (McCarthy Tétrault, 2024). Sumada a la reforma del artículo 50 de la Ley 1480 por la Ley 2439 de 2024, refuerza que la fuente de verdad y la validación no son opcionales. El hallazgo del plazo de reembolso (sección 8.5) ilustra un riesgo concreto: un agente puede amplificar un texto desactualizado; y la ausencia de un canal con radicado muestra que parte del trabajo previo al agente es de la tienda, no del Coach.

Reutilización y acoplamiento. Reutilizar el Coach evita duplicar orquestación, validación y observabilidad, pero acopla dos sistemas con ciclos de despliegue distintos. El contrato versionado, el interruptor de apagado y el fallo explícito reducen ese riesgo sin eliminarlo. Los dos registros mínimos en archivos existentes del Coach son una excepción reconocida al principio de no modificar lo existente.

12. Limitaciones

- **Metodológicas.** Revisión estructurada de alcance limitado, no sistemática; un solo proceso de búsqueda y cribado, sin doble revisión; motor de búsqueda con índice restringido; sin bases de suscripción; sin rastreo de citas; sin evaluación formal del riesgo de sesgo de cada estudio (solo clasificación por nivel).
- **De acceso.** Textos oficiales de EUR-Lex, CanLII, la SIC, la Secretaría del Senado y Función Pública no pudieron abrirse; se emplearon réplicas o comentarios secundarios señalados en el texto.
- **Temporales.** Los hechos corresponden al 27 de octubre de 2026; las normas (en particular el artículo 50 del Reglamento (UE) 2024/1689) y las prácticas de las empresas cambian con rapidez.

- **Del análisis de repositorios.** Lectura estática; métricas aproximadas; Prime no se ejecutó; no se contrastó la documentación de despliegue con los entornos reales; no se evaluó calidad clínica ni de textiles.
- **De alcance.** No hay implementación ni evaluación del agente propuesto; los controles son propuestas. Los umbrales y tamaños citados son valores tentativos.
- **De autoría.** Los autores están vinculados al proyecto cuyos repositorios se analizan; la búsqueda, el análisis y la redacción fueron asistidos por IA (sección 4.6). Pueden existir sesgos de confirmación.

13. Conclusiones

La evidencia revisada sugiere que un agente de ventas con IA para una tienda en línea es técnicamente viable y que sus beneficios comerciales son posibles pero heterogéneos y poco demostrados fuera de contextos de gran escala. Las implementaciones empresariales describen patrones comunes (modelo con herramientas y contexto, superficie de herramientas acotada, evaluación calibrada, presencia humana), mientras que los riesgos de información incorrecta, inyección de instrucciones, agencia excesiva, privacidad y transparencia tienen controles documentados que pueden incorporarse al diseño.

El análisis de los dos repositorios indica que la mayor parte del trabajo es aditivo: el Coach ya dispone de orquestación, aislamiento por rol, evidencia con fuente y herramientas con permisos, y la tienda ya es una fuente de verdad confiable de precio y existencias. Se proponen un superagente y siete agentes especializados que solo leen y proponen, con validación previa a la publicación, y un plan por etapas con criterios de salida. Quedan abiertas tres hipótesis técnicas (identidad de servicio, comportamiento de un rol nuevo y alcance de la regla de pruebas) y dos posibles brechas normativas en la tienda (plazo de reembolso y canal de atención con radicado). Antes de cualquier despliegue se requiere ejecutar el protocolo de evaluación; hasta entonces, los beneficios descritos en este manuscrito no son resultados.

Declaraciones

Uso de inteligencia artificial. Véase la sección 4.6.

Conflicto de intereses. Los autores deben declarar su relación con el proyecto GoToGym, cuyos repositorios se analizan: [pendiente de completar por los autores].

Financiamiento. [Pendiente de completar por los autores].

Disponibilidad de datos y código. Los repositorios analizados no se publican con este manuscrito. Se indican las confirmaciones analizadas (*06ec012e* y *a0e9d0e*) para trazabilidad interna. Las consultas de búsqueda se listan en el Apéndice A.

Referencias

AI Incident Database. (2023, 18 de diciembre). *Incident 622: Chevrolet dealer chatbot agrees to sell Tahoe for $1*. https://incidentdatabase.ai/entities/chevrolet-of-watsonville

Beurer-Kellner, L., Buesser, B., Creţu, A.-M., Debenedetti, E., Dobos, D., Fabian, D., Fischer, M., Froelicher, D., Grosse, K., Naeff, D., Ozoani, E., Paverd, A., Tramèr, F. y Volhejn, V. (2025). *Design patterns for securing LLM agents against prompt injections* [Preprint]. arXiv. https://arxiv.org/abs/2506.08837

Brynjolfsson, E., Li, D. y Raymond, L. R. (2025). Generative AI at work. *The Quarterly Journal of Economics, 140*(2), 889–942. https://doi.org/10.1093/qje/qjae044

Cemri, M., Pan, M. Z., Yang, S., Agrawal, L. A., Chopra, B., Tiwari, R., Keutzer, K., Parameswaran, A., Klein, D., Ramchandran, K., Zaharia, M., Gonzalez, J. E. y Stoica, I. (2025). *Why do multi-agent LLM systems fail?* [Preprint]. arXiv. https://arxiv.org/abs/2503.13657

Civil Resolution Tribunal of British Columbia. (2024). *Moffatt v. Air Canada*, 2024 BCCRT 149 (14 de febrero de 2024). [Decisión citada a través de comentario jurídico; el texto completo no fue accesible]. Véase McCarthy Tétrault (2024).

Congreso de la República de Colombia. (2011). *Ley 1480 de 2011, por medio de la cual se expide el Estatuto del Consumidor y se dictan otras disposiciones* (12 de octubre de 2011). Diario Oficial n.º 48.220.

Congreso de la República de Colombia. (2012). *Ley Estatutaria 1581 de 2012, por la cual se dictan disposiciones generales para la protección de datos personales* (17 de octubre de 2012). Diario Oficial n.º 48.587 del 18 de octubre de 2012.

Congreso de la República de Colombia. (2024). *Ley 2439 de 2024, por medio de la cual se modifica la Ley 1480 de 2011 y se crean medidas de protección en favor del consumidor de comercio electrónico* (19 de diciembre de 2024). Diario Oficial n.º 52.975 del 29 de diciembre de 2024.

Cuatrecasas. (s. f.). *Guía para el uso responsable de IA y datos personales en Colombia* [Comentario jurídico]. https://www.cuatrecasas.com/es/latam/tecnologia-medios-digitales/art/guia-uso-responsable-ia-datos-personales-colombia

Debenedetti, E., Zhang, J., Balunović, M., Beurer-Kellner, L., Fischer, M. y Tramèr, F. (2024). *AgentDojo: A dynamic environment to evaluate prompt injection attacks and defenses for LLM agents* [Preprint]. arXiv. https://arxiv.org/abs/2406.13352

Debenedetti, E., Shumailov, I., Fan, T., Hayes, J., Carlini, N., Fabian, D., Kern, C., Shi, C., Terzis, A. y Tramèr, F. (2025). *Defeating prompt injections by design* [Preprint]. arXiv. https://arxiv.org/abs/2503.18813

Fang, L., Yuan, Z., Zhang, K., Donati, D. y Sarvary, M. (2025). *Generative AI and sales productivity: Field experiments in online retail* [Preprint, versión revisada en 2026]. arXiv. https://arxiv.org/abs/2510.12049

Gosby, D. (2025, 6 de junio). *Walmart: The future of shopping is agentic. Meet Sparky.* Walmart Corporate. https://corporate.walmart.com/news/2025/06/06/walmart-the-future-of-shopping-is-agentic-meet-sparky

Greshake, K., Abdelnabi, S., Mishra, S., Endres, C., Holz, T. y Fritz, M. (2023). Not what you've signed up for: Compromising real-world LLM-integrated applications with indirect prompt injection. En *Proceedings of the 16th ACM Workshop on Artificial Intelligence and Security* (pp. 79–90). ACM. https://doi.org/10.1145/3605764.3623985

Huang, L., Yu, W., Ma, W., Zhong, W., Feng, Z., Wang, H., Chen, Q., Peng, W., Feng, X., Qin, B. y Liu, T. (2025). A survey on hallucination in large language models: Principles, taxonomy, challenges, and open questions. *ACM Transactions on Information Systems, 43*(2), 1–55. https://doi.org/10.1145/3703155

Jannach, D., Manzoor, A., Cai, W. y Chen, L. (2021). A survey on conversational recommender systems. *ACM Computing Surveys, 54*(5), 1–36. https://doi.org/10.1145/3453154

Ji, Z., Lee, N., Frieske, R., Yu, T., Su, D., Xu, Y., Ishii, E., Bang, Y. J., Madotto, A. y Fung, P. (2023). Survey of hallucination in natural language generation. *ACM Computing Surveys, 55*(12), 1–38. https://doi.org/10.1145/3571730

Jin, Y., Li, Z., Zhang, C., Cao, T., Gao, Y., Jayarao, P., Li, M., Liu, X., Sarkhel, R., Tang, X., Wang, H., Wang, Z., Xu, W., Yang, J., Yin, Q., Li, X., Nigam, P., Xu, Y., Chen, K., ... Yin, B. (2024). Shopping MMLU: A massive multi-task online shopping benchmark for large language models. En *Advances in Neural Information Processing Systems 37 (NeurIPS 2024), Datasets and Benchmarks Track*. https://proceedings.neurips.cc/paper_files/paper/2024/hash/2049d75dd13db049897562bcf7d59da8-Abstract.html

Klarna. (2024, 27 de febrero). *Klarna AI assistant handles two-thirds of customer service chats in its first month* [Comunicado de prensa]. https://www.klarna.com/international/press/klarna-ai-assistant-handles-two-thirds-of-customer-service-chats-in-its-first-month/

Lewis, P., Perez, E., Piktus, A., Petroni, F., Karpukhin, V., Goyal, N., Küttler, H., Lewis, M., Yih, W.-t., Rocktäschel, T., Riedel, S. y Kiela, D. (2020). *Retrieval-augmented generation for knowledge-intensive NLP tasks* [Preprint]. arXiv. https://arxiv.org/abs/2005.11401

Luo, X., Tong, S., Fang, Z. y Qu, Z. (2019). Frontiers: Machines vs. humans: The impact of artificial intelligence chatbot disclosure on customer purchases. *Marketing Science, 38*(6), 937–947. https://doi.org/10.1287/mksc.2019.1192

Mathur, A., Acar, G., Friedman, M. J., Lucherini, E., Mayer, J., Chetty, M. y Narayanan, A. (2019). Dark patterns at scale: Findings from a crawl of 11K shopping websites. *Proceedings of the ACM on Human-Computer Interaction, 3*(CSCW), 1–32. https://doi.org/10.1145/3359183

McCarthy Tétrault. (2024, 19 de febrero). [Comentario jurídico sobre *Moffatt v. Air Canada*, 2024 BCCRT 149]. https://www.mccarthy.ca/en/insights/blogs/techlex/moffatt-v-air-canada-misrepresentation-ai-chatbot

McNamara, A. (2025, 26 de agosto). *Building production-ready agentic systems: Lessons from Shopify Sidekick*. Shopify Engineering. https://shopify.engineering/building-production-ready-agentic-systems

National Institute of Standards and Technology. (2024). *Artificial intelligence risk management framework: Generative artificial intelligence profile* (NIST AI 600-1). U.S. Department of Commerce. https://doi.org/10.6028/NIST.AI.600-1

Noels, S., Rogiers, A., Buyl, M. y De Bie, T. (2024). *Persuasion with large language models: A survey of empirical evidence, study methodologies, and ethical implications* [Preprint]. arXiv. https://arxiv.org/abs/2411.06837

OWASP GenAI Security Project. (2025a). *LLM01:2025 Prompt injection*. OWASP Top 10 for LLM Applications 2025. https://genai.owasp.org/llmrisk/llm01-prompt-injection/

OWASP GenAI Security Project. (2025b). *LLM06:2025 Excessive agency*. OWASP Top 10 for LLM Applications 2025. https://genai.owasp.org/llmrisk/llm062025-excessive-agency/

Park, J., Foo, S., Katti, S., Sinkar, G., Perianayagam, S. y Trikande, S. (2025, 20 de noviembre). *How Rufus scales conversational shopping experiences to millions of Amazon customers with Amazon Bedrock*. AWS Machine Learning Blog. https://aws.amazon.com/blogs/machine-learning/how-rufus-scales-conversational-shopping-experiences-to-millions-of-amazon-customers-with-amazon-bedrock

Parlamento Europeo y Consejo de la Unión Europea. (2024). *Reglamento (UE) 2024/1689 por el que se establecen normas armonizadas en materia de inteligencia artificial* (13 de junio de 2024). Diario Oficial de la Unión Europea, L, 12 de julio de 2024. [Artículo 50 consultado en una réplica no oficial: https://artificialintelligenceact.eu/article/50/; el sitio oficial EUR-Lex no devolvió contenido].

Perez, F. y Ribeiro, I. (2022). *Ignore previous prompt: Attack techniques for language models* [Preprint]. arXiv. https://arxiv.org/abs/2211.09527

Rajasekar, A. A., Tangarajan, P., Nainani, A., Batwal, A., Dandin, V. R., Trivedi, A. y Ersoy, O. (2025). *Flippi: End to end GenAI assistant for e-commerce* [Preprint]. arXiv. https://arxiv.org/abs/2507.05788

Schick, T., Dwivedi-Yu, J., Dessì, R., Raileanu, R., Lomeli, M., Zettlemoyer, L., Cancedda, N. y Scialom, T. (2023). *Toolformer: Language models can teach themselves to use tools* [Preprint]. arXiv. https://arxiv.org/abs/2302.04761

Schluntz, E. y Zhang, B. (2024, 19 de diciembre). *Building effective agents*. Anthropic. https://www.anthropic.com/engineering/building-effective-agents

Shibu, S. (2025, 9 de mayo). *Klarna is hiring customer service agents after AI couldn't cut it on calls, according to the company's CEO*. Entrepreneur. https://www.entrepreneur.com/business-news/klarna-ceo-reverses-course-by-hiring-more-humans-not-ai/491396

Superintendencia de Industria y Comercio. (2024). *Circular Externa n.º 002 de 2024: Lineamientos sobre el tratamiento de datos personales en sistemas de inteligencia artificial* (21 de agosto de 2024). [Contenido consultado a través de Cuatrecasas (s. f.); el PDF oficial devolvió HTTP 404].

Walmart Inc. (2026a, 21 de octubre). *Walmart makes it possible for agents to shop on behalf of customers, while keeping customers in control*. https://corporate.walmart.com/news/2026/10/Making-It-Possible-for-Agents-to-Shop-on-Behalf-of-Customers

Walmart Inc. (2026b). *Walmart is building for an agentic commerce future* [Página web, consultada el 27 de octubre de 2026]. https://corporate.walmart.com/about/technology

Wang, L., Huang, N., He, Y., Liu, D., Guo, X., Sun, Y. y Chen, G. (2025). Artificial intelligence (AI) assistant in online shopping: A randomized field experiment on a livestream selling platform. *Information Systems Research, 36*(4), 2358–2374. https://doi.org/10.1287/isre.2023.0103

Wu, Q., Bansal, G., Zhang, J., Wu, Y., Li, B., Zhu, E., Jiang, L., Zhang, X., Zhang, S., Liu, J., Awadallah, A. H., White, R. W., Burger, D. y Wang, C. (2023). *AutoGen: Enabling next-gen LLM applications via multi-agent conversation* [Preprint]. arXiv. https://arxiv.org/abs/2308.08155

Yao, S., Chen, H., Yang, J. y Narasimhan, K. (2022). *WebShop: Towards scalable real-world web interaction with grounded language agents* [Preprint; presentado en NeurIPS 2022]. arXiv. https://arxiv.org/abs/2207.01206

Yao, S., Zhao, J., Yu, D., Du, N., Shafran, I., Narasimhan, K. y Cao, Y. (2022). *ReAct: Synergizing reasoning and acting in language models* [Preprint]. arXiv. https://arxiv.org/abs/2210.03629

Yao, S., Shinn, N., Razavi, P. y Narasimhan, K. (2024). *τ-bench: A benchmark for tool-agent-user interaction in real-world domains* [Preprint]. arXiv. https://arxiv.org/abs/2406.12045

Apéndice A. Consultas de búsqueda ejecutadas (27 de octubre de 2026)

Motor de búsqueda web de propósito general, modo estándar. La consulta 24 se restringió al dominio *corporate.walmart.com*. Las verificaciones en Crossref y arXiv se hicieron por identificador, no por consulta de texto, salvo la búsqueda bibliográfica por título del estudio descartado (sección 4.4).

Tabla A1

Consultas de búsqueda

N.º	Consulta (tal como se ejecutó)	Propósito
1	large language model shopping assistant e-commerce conversational agent survey	Panorama; no se halló una revisión específica
2	tau-bench benchmark tool-agent-user interaction real-world domains retail	Fiabilidad de agentes
3	WebShop towards scalable real-world web interaction with grounded language agents	Entorno de compras
4	Amazon Rufus generative AI shopping assistant how it works architecture	Caso empresarial
5	Moffatt v. Air Canada 2024 BCCRT 149 chatbot negligent misrepresentation	Responsabilidad
6	OWASP Top 10 for LLM Applications 2025 prompt injection excessive agency	Riesgos de seguridad
7	Klarna AI assistant press release 2.3 million conversations two-thirds of customer service chats	Caso empresarial
8	Klarna reverses AI customer service hires humans again Siemiatkowski 2025	Seguimiento del caso
9	Chevrolet dealership ChatGPT chatbot prompt injection agreed to sell Tahoe for $1 December 2023	Incidente
10	EU AI Act Article 50 transparency obligations providers deployers chatbots inform natural persons interacting with AI system	Transparencia
11	Shopping MMLU massive multi-task online shopping benchmark for large language models	Benchmark
12	Anthropic Building effective agents workflows versus agents augmented LLM	Definiciones de agente
13	Luo Tong Fang Qu 2019 Marketing Science Machines vs. humans chatbot disclosure purchase rates 79.7% abstract	Revelación del chatbot
14	Erik Schluntz Barry Zhang Building effective agents Anthropic December 2024	Autoría
15	Shopify engineering Building production-ready agentic systems Sidekick lessons	Caso empresarial
16	NIST AI 600-1 AI RMF Generative AI Profile confabulation July 2024	Marco de riesgos
17	Superintendencia de Industria y Comercio Colombia guía tratamiento de datos personales en sistemas de inteligencia artificial	Normativa colombiana
18	Ley 1480 de 2011 Estatuto del Consumidor artículo 47 retracto artículo 23 información mínima comercio electrónico texto oficial	Normativa colombiana
19	Ley 2439 de 2024 modifica artículo 47 Ley 1480 derecho de retracto plazo días hábiles cambio	Normativa colombiana
20	Ley 1581 de 2012 Diario Oficial 48.587 protección de datos personales texto oficial	Normativa colombiana
21	Walmart super agents Sparky AI shopping assistant super agent announcement 2025	Caso empresarial
22	randomized field experiment generative AI shopping assistant effect on conversion online retailer causal evidence 2025 working paper	Evidencia causal
23	Mathur Dark Patterns at Scale 11,000 shopping websites 1,818 instances false urgency scarcity	Patrones oscuros
24	Walmart unveils new agent experiences Sparky Marty Associate Developer super agents July 2025 (dominio restringido)	Fuente primaria
25	Reglamento (UE) 2024/1689 inteligencia artificial 13 de junio de 2024 Diario Oficial L 12.7.2024 artículo 50	Cita oficial

N.º	Consulta (tal como se ejecutó)	Propósito
26	Ley 1480 de 2011 Estatuto del Consumidor 12 de octubre de 2011 Diario Oficial No. 48.220	Cita oficial

Nota. Las consultas en español se ejecutaron tal cual figuran; las demás, en inglés.

Apéndice B. Ejemplo ilustrativo del contrato tienda–Coach

Ejemplo **ilustrativo**, no implementado. Los campos y valores son propuestas; los precios son cadenas decimales y los identificadores, de muestra.

```
SOLICITUD (servidor de la tienda -> servicio de IA, firmada con HMAC y marca de tiempo)
{
  "request_id": "<uuid-por-turno>",  "conversation_id": "shop-<uuid>",  "locale": "es",
  "message": "Busco leggins para entrenar, talla M, hasta 450 mil",
  "visitor": {"subject": "shop_v_<hash>", "authenticated": false},
  "page": {"url_name": "tienda:producto_detail", "product_id": 12, "variant_id": 31},
  "cart": {"count": 1, "subtotal": "400000.00",
           "lines": [{"variant_id": 31, "qty": 1, "unit_price": "400000.00", "available": 5}]},
  "shop_flags": {"purchases_paused": false, "payments_live": false, "currency": "COP"},
  "evidence": {"candidates": [{"product_id": 12, "price": "400000.00",
               "variants": [{"id": 31, "size": "M", "color": "gris", "available": 5}]}]},
  "timestamp": 1790000000, "signature": "<hmac-sha256>"
}

RESPUESTA (servicio de IA -> servidor de la tienda)
{
  "reply": "<texto ya validado>",
  "ui_actions": [{"type": "add_to_cart", "variant_id": 31},
                 {"type": "open_product", "product_id": 12}],
  "product_cards": [{"product_id": 12, "reason": "<motivo basado en evidencia>"}],
  "handoff": null,
  "meta": {"agents_used": ["discovery", "fit"],
           "evidence_refs": ["commerce.product:12@<v>"],
           "status": "ok", "retry_after_seconds": null}
}
```