Manuscrito científico técnico 02

CommerceCustomerContext, orquestación comercial y personalización QAF | Propuesta de implementación v1.0

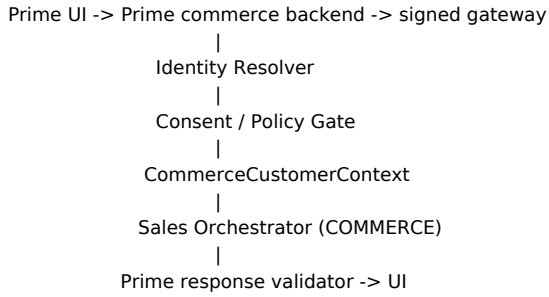
Resumen y contribución propuesta

Se diseña CommerceCustomerContext, una representación mínima y consentida de preferencias comerciales para personalizar la tienda GoToGym mediante Quantum Coach, preservando la autoridad de Prime sobre catálogo, precios, inventario y acciones de compra. La propuesta distingue recuperación de contexto, razonamiento comercial y validación final de acciones.

1. Problema técnico y alcance

El widget actual puede mostrar indisponibilidad del servicio. Además, el identificador shop_u_ no permite resolver el perfil del Coach. El objetivo no es compartir toda la memoria del Coach: es permitir una personalización explicable y útil, sin acceder automáticamente a datos clínicos, wearables, diagnósticos o documentos privados.

2. Arquitectura funcional



El orquestador puede convocar especialistas de productos, tallas, combinaciones, envíos, políticas, carrito y atención humana; deben verificarse los nombres y contratos reales de los siete especialistas descritos previamente. Solo la capa final produce la respuesta al usuario y Prime vuelve a comprobar todas las acciones.

3. Contrato de datos mínimo

```
CommerceCustomerContextV1 = {
 "known": true, "customer_ref": "opaque", "locale": "es",
 "display_name": "optional", "favorite_sport": "optional",
 "preferred_sizes": [], "favorite_categories": [],
 "returning_customer": false, "consent_version": "v1",
 "provenance": {}, "expires_at": "ISO-8601"
}
```

No incluir email, teléfono, dirección, contraseñas, access tokens, estado médico, peso, IMC, biometría, raw wearable data ni memoria privada. Nombre visible y preferencias solo se transmiten si existe base jurídica y autorización aplicable. Usar finalidad explícita, TTL corto, control de acceso y eliminación/revocación.

4. Modelo QAF propuesto: selección contextual

Representamos cada producto candidato j mediante x_j = [afinidad deportiva, compatibilidad de talla, disponibilidad, ajuste al presupuesto, coherencia con carrito, confianza de evidencia]. Una puntuación propuesta es $S_j = w^T x_j - \lambda P_j - \mu D_j$, donde P_j penaliza uso de atributos sensibles o inciertos y D_j penaliza falta de evidencia. La selección maximiza $\Sigma_j y_j S_j$ con $y_j \in \{0,1\}$, $\Sigma_j y_j \leq k$ y restricciones duras de stock y política. Esta es una formalización experimental inspirada en los índices de coherencia/eficiencia QAF, no una validación empírica de ventaja cuántica.

5. Coherencia, incertidumbre y abstención

La recomendación debe incluir procedencia: catálogo Prime, preferencia declarada, compra anterior o inferencia. Para preferencias inferidas, exigir confianza calibrada; si falta talla confirmada, preguntar antes de asegurar compatibilidad. Definir C = evidencia_consistente / evidencia_total como métrica operacional y η = recomendaciones_útiles / coste_de_servicio. Estas definiciones son propuestas específicas de comercio y requieren calibración experimental.

6. Pseudocódigo del flujo

```
def handle_commerce(request):
    verify_service_request(request)
    identity = resolve_identity(request.identity_ref)
    consent = load_commerce_consent(identity)
    context = build_allowlisted_context(identity, consent)
    evidence = prime_evidence(request)
    proposals = rank_products(context, evidence)
    draft = sales_orchestrator(proposals, evidence)
    return validate_against_prime(draft, evidence)
```

En implementación distribuida, la validación final de precios, stock, URL, variante y acciones ocurre en Prime contra su base actual. El modelo jamás ejecuta directamente un pedido, modifica precio ni autoriza un pago.

7. Continuidad conversacional y degradación

La memoria COMMERCE se segmenta por sujeto seudónimo, propósito y TTL. No mezclar conversaciones de distintos usuarios o sesiones. Cuando el Coach no responda, mostrar fallback local con contacto humano, estado de servicio y reintento controlado; nunca afirmar que hay disponibilidad de un producto sin consulta vigente a Prime. Instrumentar tiempos por etapa: firma, red, resolución, contexto, orquestación y saneamiento.

8. Diseño experimental y métricas

Comparar A/B: vendedor anónimo actual vs. vendedor personalizado con consentimiento. Variables: CTR en productos, adición al carrito, conversión, recurrencia, tiempo a primera respuesta, p50/p95 de latencia, aceptación de recomendaciones, tasa de handoff, errores y quejas de privacidad. Predefinir tamaño de muestra, duración, segmentación, intervalos de confianza y criterio de parada; evitar concluir causalidad sin experimento.

9. Seguridad y gobierno

Aplicar separación de responsabilidades: identidad verifica sujeto; política decide campos; Coach recomienda; Prime valida acciones. Auditar consentimiento, fuente, versión y revocación. El modelo no debe recibir identificadores federados en claro. Ejecutar pruebas de prompt injection con descripciones de producto y mensajes de cliente; las instrucciones en texto externo no pueden modificar permisos ni contratos.

10. Roadmap de integración y pruebas

Sprint 1: contrato y feature flag, gateway COMMERCE recuperado y pruebas de salud. Sprint 2: resolver identidad, consentimiento y contexto mínimo. Sprint 3: personalización de ranking y UX. Sprint 4: pruebas end-to-end con usuario conocido, anónimo, sin consentimiento, error de red y sesión expirada; canary y rollback. Entregables: tests, esquema JSON, migraciones aditivas, métricas, runbook y documentación.

11. Experiencia final verificable

Usuario conocido y autorizado: saludo contextual, sugerencias basadas en preferencias comerciales comprobables, talla únicamente cuando existe evidencia, productos vigentes y carrito persistente. Usuario anónimo: asesoría general sin perfil. Usuario que revoca consentimiento: retorno inmediato al modo no personalizado. El texto final debe ser claro, verificable y sin afirmaciones clínicas o textiles no respaldadas.

12. Limitaciones y trabajo futuro

No se han ejecutado pruebas de producción ni validado experimentalmente las fórmulas propuestas. Antes de afirmar que la personalización funciona, deben verificarse endpoints reales, credenciales de servicio, conectividad y consentimientos. Trabajo futuro: aprendizaje de preferencias mediante retroalimentación explícita, evaluación de sesgo y optimización multiobjetivo con restricciones de privacidad.